

Preservación de la identidad vocal del paciente mediante clonación de voz *zero-shot*, *watermarking* y *anti-spoofing* en un entorno hospitalario *on-premise*

Premios Salut Innova UIB-HLL Son Espases · 4ª edición (2026)

Categoría:	Inteligencia artificial y datos masivos (<i>big data</i>)
Proponentes:	Marc Link Cladera (graduado, EPS-UIB) · Andrés Borrás Santos (graduado, EPS-UIB) Antonio Contestí Coll (graduado, EPS-UIB) Dra. Amaya Roldán Fidalgo (FEA, Servicio de Otorrinolaringología y Cirugía de Cabeza y Cuello, Hospital Universitario Son Llàtzer, IB-Salut)
Origen:	desarrollo en el marco del convenio UIB · IB-Salut · FUEIB; aplicación clínica <i>on-premise</i> a partir de un <i>benchmark</i> previo de 528 generaciones sobre cuatro modelos <i>open-weight</i> de clonación de voz en castellano peninsular.

1. Justificación clínica

La voz es un componente esencial de la identidad personal. En pacientes con **cáncer de laringe, cirugía de cabeza y cuello, esclerosis lateral amiotrófica (ELA), intubación prolongada o daño neurológico**, la pérdida del habla afecta a la comunicación funcional pero también a la autoestima, a la interacción social y a la adherencia terapéutica. El Servicio de Otorrinolaringología y Cirugía de Cabeza y Cuello del Hospital Universitario Son Llàtzer impulsa este proyecto para que el paciente pueda, antes de perder su voz o a partir de voz residual, **conservar su identidad vocal en forma de un perfil sintético reutilizable** para comunicación asistida, lectura de informes o mensajes personales. Hoy, los servicios comerciales que permiten esto exigen subir audio biométrico a servidores fuera de la UE, sin marca de agua detectable por el operador y sin base legal específica bajo el art. 9 del RGPD ni del art. 50 de la Ley de IA UE 2024/1689. El proyecto resuelve esa brecha desplegando el sistema íntegramente *on-premise* en la infraestructura del hospital, sin tránsito a la nube, con consentimiento específico y trazabilidad forense en cada audio sintético.

2. Innovación propuesta

El sistema implementa un **pipeline clínico completo de clonación de voz *zero-shot*** con tres modelos *open-weight* integrados y un cuarto modelo comercial bloqueado por defecto. Frontend Vue 3 trilingüe con grabador propio (*spectrograma* en vivo, VU meter, *downsample* a 16 kHz mono PCM 16-bit) y consentimiento renderizado por el servidor. Backend FastAPI asíncrono con SQLAlchemy 2 (*async*), migraciones Alembic, OIDC *mock* HS256 con migración a Keycloak en piloto, y *audit log append-only* con cadena de hashes SHA-256 verificable extremo a extremo. Workers nativos sobre la GPU **NVIDIA DGX Spark** (chip Grace Blackwell GB10, ARM64, CUDA 13.0, 130 GB VRAM unificada) con *LRU eviction* tras 10 min, una cola RabbitMQ por modelo y Redis *pub/sub* para progreso en tiempo real. **Toda síntesis pasa por dos salvaguardas obligatorias:** (i) marca de agua imperceptible — PerTh nativo en Chatterbox (verificado 132/132 en el *benchmark*) o AudioSeal post-hoc en OmniVoice y Qwen3-TTS— con *verify* almacenado; (ii) puntuación AASIST *anti-spoofing* persistida por *job*, deseablemente alta (audio claramente detectable como sintético). Almacenamiento en MinIO cifrado con KMS Vault *transit*. La integración con ElevenLabs queda *deshabilitada por defecto* con modal de confirmación bloqueante, persistiendo *deployment_safe=false* y *watermark_scheme=none*; uso restringido a comparativas no clínicas. Empaquetado en Docker Compose para piloto multi-host (PC + Spark) y en *Helm chart* con *ExternalSecrets/SealedSecrets* para producción en Kubernetes.

3. Apoyo al estado del arte

El proyecto evalúa con criterios reproducibles el panorama *open-weight* 2026 de clonación de voz *zero-shot* — codec LM, no autorregresivos, *flow matching*, *diffusion*— y avanza con cuatro aportaciones: (i) un **benchmark de 528 generaciones** (4 modelos × 4 locutores VoxPopuli-ES × 3 longitudes de referencia × 11 frases, tasa de fallo 0 %) con métricas automáticas WER (*faster-whisper large-v3*), UTMOS22 real, similitud WavLM-large, similitud ECAPA-TDNN, AASIST y verificación de *watermark*; (ii) un conjunto de **decision gates** fijados *a priori* (WER < 8 %, UTMOS ≥ 3,5, sim WavLM > 0,75, TTFA < 3 s, licencia permisiva, fallos < 5 %) que evitan la trampa habitual de la comparación basada en *demos*; (iii) la **cuantificación del riesgo *anti-spoofing* en XTTS-v2** —score AASIST de 0,053, audio prácticamente indistinguible de humano—, junto con el dictamen sobre su licencia CPML, motivan su exclusión clínica; (iv) la posición pública sobre ElevenLabs: incumple el art. 50 de la Ley de IA UE 2024/1689 sobre trazabilidad por ausencia de marca de agua detectable, y queda contractualmente bloqueada para datos clínicos.

4. Contribución original

La aportación más original es la **traslación de las salvaguardas regulatorias a artefactos verificables del sistema**: cada audio sintético lleva marca de agua imperceptible *verificable post-hoc*, un score AASIST persistido y una entrada en el *audit log* con *hash* encadenado SHA-256 que un auditor externo puede recorrer. La selección de modelos no se justifica con eslóganes sino con un *benchmark* de 528 generaciones cuyos resultados crudos y *decision gates* están publicados. La arquitectura es *on-premise* por construcción: ninguna voz de paciente abandona la red hospitalaria, y la única integración comercial (ElevenLabs) queda contractualmente bloqueada para datos clínicos. La aplicación cierra el ciclo: consentimiento específico, captura, perfil de voz, síntesis, *watermark*, *anti-spoofing*, auditoría y entrega firmada al clínico, todo en una pieza desplegable.

5. Resultados clave

Cobertura del <i>benchmark</i>	528 generaciones · 4 modelos · 4 locutores VoxPopuli-ES (2M+2F) · 3 longitudes de referencia (3, 10, 30 s) · 11 frases · tasa de fallo 0 %.
Chatterbox (MIT, por defecto)	WER 8,0 % · UTMOS22 3,11 · sim WavLM 0,707 · AASIST 0,471 · <i>watermark</i> PerTh 132/132 · TTFA 3,2 s · RTF 0,50.
OmniVoice (Apache 2.0)	Mejor similitud de locutor: sim WavLM 0,787 · sim ECAPA-TDNN 0,756 · Audio-Seal post-hoc obligatorio.
Qwen3-TTS (Apache 2.0)	WER 8,6 % · UTMOS22 3,11 · sim WavLM 0,775 · AASIST 0,629 · <i>venv</i> aislado transformers<5.
XTTS-v2 (CPML, excluido)	AASIST 0,053 (riesgo <i>anti-spoofing</i> crítico) + bloqueo de licencia hasta dictamen jurídico.
ElevenLabs (no clínico)	Sin <i>watermark</i> detectable ⇒ incompatible con art. 50 Ley IA UE 2024/1689; bloqueado por defecto.
Latencia extremo a extremo	3–7 s según modelo, incluyendo cola, inferencia, postproceso <i>watermark</i> y AASIST.
Hardware	DGX Spark GB10, ARM64, CUDA 13.0, 130 GB VRAM unificada. Compartido por LRU con otros tenants del hospital.

6. Impacto económico y social

Para el paciente: preserva la identidad vocal antes o después de una cirugía oncológica de cabeza y cuello, una laringectomía o el avance de una enfermedad neuromuscular, ofreciendo continuidad emocional y autonomía comunicativa con su propia voz. **Para el sistema sanitario:** elimina la dependencia de servicios cloud cuyo uso clínico sería incompatible con RGPD, art. 9 (dato biométrico) y con el art. 50 de la Ley de IA UE 2024/1689 (trazabilidad); reutiliza la infraestructura GPU compartida del hospital ya desplegada para otros proyectos asistenciales. **Para la investigación:** la publicación del protocolo de *benchmark*, de los *decision gates* y del posicionamiento ético-jurídico sobre licencias (CPML, condiciones comerciales) y sobre *watermarking* obligatorio cubre un hueco poco documentado en el ámbito hospitalario. **Para la sociedad:** código y documentación publicados en GitHub bajo licencia CC BY-NC 4.0; refuerza la soberanía de datos sanitarios.

7. Cooperación UIB · IB-Salut

- **UIB** (Escola Politècnica Superior) — Marc Link Cladera, Andrés Borrás Santos y Antonio Contestí Coll, graduados en Ingeniería Informática, asumen el diseño técnico, la implementación, la auditoría algorítmica, el *benchmark* de 528 generaciones y la integración *end-to-end*.
- **IB-Salut, Hospital Universitario Son Llàtzer** — Dra. Amaya Roldán Fidalgo, FEA del Servicio de Otorrinolaringología y Cirugía de Cabeza y Cuello, aporta la definición de la población diana, los protocolos de captura de voz residual, los criterios de aceptación clínica y la coordinación con consultas de Logopedia, Rehabilitación y Maxilofacial.
- **Marco institucional** — convenio UIB · IB-Salut · FUEIB en vigor, alineado con la línea estratégica de IA clínica del HUSLL y con la infraestructura GPU compartida del hospital.
- **Equipo mixto por construcción** — la candidatura cumple el criterio de Cooperación UIB · IB-Salut (10 %) sin necesidad de adaptaciones; el liderazgo clínico y el liderazgo técnico están repartidos por diseño desde el origen del proyecto.

8. Madurez del proyecto

El sistema es un **prototipo operativo** desplegable extremo a extremo, con *benchmark* reproducible publicado y arquitectura validada en Docker Compose multi-host y en *Helm chart* para Kubernetes. *Trabajo en curso:* aprobación del protocolo de escucha ciega clínica por el Comité de Ética Asistencial, dictamen del Servicio Jurídico sobre la licencia CPML de XTTS-v2, *fine-tuning* con voz propia del paciente sobre 2–5 h de audio para la fase de validación clínica, e integración con SISN2 y consultas de Logopedia. *Trabajo futuro:* publicación científica del marco de salvaguardas (*watermark* + AASIST + *audit chain*) y de la postura sobre licencias *open-weight* en el ámbito sanitario europeo.

Material disponible para evaluación:

Repositorio público del proyecto	https://github.com/tcontesti/voice_cloning_app
Landing page (presentación visual)	https://tcontesti.github.io/voice_cloning_app/
Documentación técnica (wiki, 10 páginas)	https://github.com/tcontesti/voice_cloning_app/wiki
Resumen ejecutivo (este documento, PDF)	https://github.com/tcontesti/voice_cloning_app/tree/main/docs
Documentación técnica adicional	https://github.com/tcontesti/voice_cloning_app/tree/main/docs
Memoria académica completa	pendiente de redacción
Demostración en vivo del prototipo	disponible bajo demanda en LAN Hospital Universitario Son Llàtzer